

## COMPARING THE MOORE-PENROSE PSEUDOINVERSE AND GRADIENT DESCENT FOR SOLVING LINEAR REGRESSION PROBLEMS : A PERFORMANCE ANALYSIS

This work compares two main methods for solving linear regression problems : the Moore-Penrose pseudoinverse (a direct or analytical mathematical solution) and gradient descent (an iterative method).

Linear regression models the relationship between a dependent variable and one or more independent variables, seeking the parameters that minimize the squared error (OLS). It can be solved using the Moore-Penrose pseudoinverse, which provides an exact solution, or by gradient descent, which iteratively adjust the parameters. Its simplicity and efficiency make it fundamental in numerous scientific fields.

The depth of the analysis is reflected in the examination of the mathematical foundations of each method. For the pseudoinverse, the author highlights its practical implementation through Singular Value Decomposition (SVD), which avoids the numerical issues associated with directly computing  $(X^T X)^{-1}$ . This approach ensures numerical stability but has a computational complexity dominated by the cubic term  $O(d^3)$ , limiting its applicability to high-dimensional problems.

Gradient descent, on the other hand, is analyzed from the perspective of iterative optimization, where convergence toward the minimum depends on the learning rate and the spectral properties of the design matrix. The author theoretically explores how the condition number of  $X$  critically influences the algorithm's behavior. For well-conditioned matrices, convergence is monotonic, whereas in ill-conditioned problems, numerical instability and extremely slow convergence emerge.

The conclusions point toward a more nuanced understanding of the trade-off between analytical and iterative methods, suggesting that the optimal choice is determined by the interaction between dimensionality, numerical conditioning, and available computational resources. The work lays the theoretical foundation for the development of hybrid approaches that combine the advantages of both paradigms, particularly in the context of regularization and adaptive optimization.



# COMPARACION DE RENDIMIENTO ENTRE METODOS DE OPTIMIZACION

El objetivo de esta prueba fue evaluar la eficiencia computacional del metodo de regresión lineal de R ( $lm()$ ) en comparación con el algoritmo de gradiente descendente implementado manualmente. Para ello, se generaron conjuntos de datos simulados de diferentes tamaños.

Durante la ejecución se registraron dos metricas principales

- El tiempo de procesamiento (en segundos)
- El uso de memoria (en megabytes).

Los resultados obtenidos se visualizan mediante los graficos comparativos, donde se evidencia la diferencia entre el comportamiento del modelo  $lm()$  - basado en calculos matriciales optimizados y el gradiente descendente, que requiere multiples iteraciones para converger.

Tamaño	Metodo	Tiempo	Memoria
$1e+02$	$lm$	0.00	0.01824
$1e+02$	gradiente	0.02	7.997177
$1e+03$	$lm$	0.00	0.169273
$1e+03$	gradiente	0.06	76.67546
$5e+03$	$lm$	0.00	0.864830
$5e+03$	gradiente	0.34	381.91227
$1e+04$	$lm$	0.00	1.728416
$1e+04$	gradiente	0.78	763.45829

El experimento comparó el rendimiento del metodo  $lm()$  de R y el gradiente descendente para realizar regresión lineal

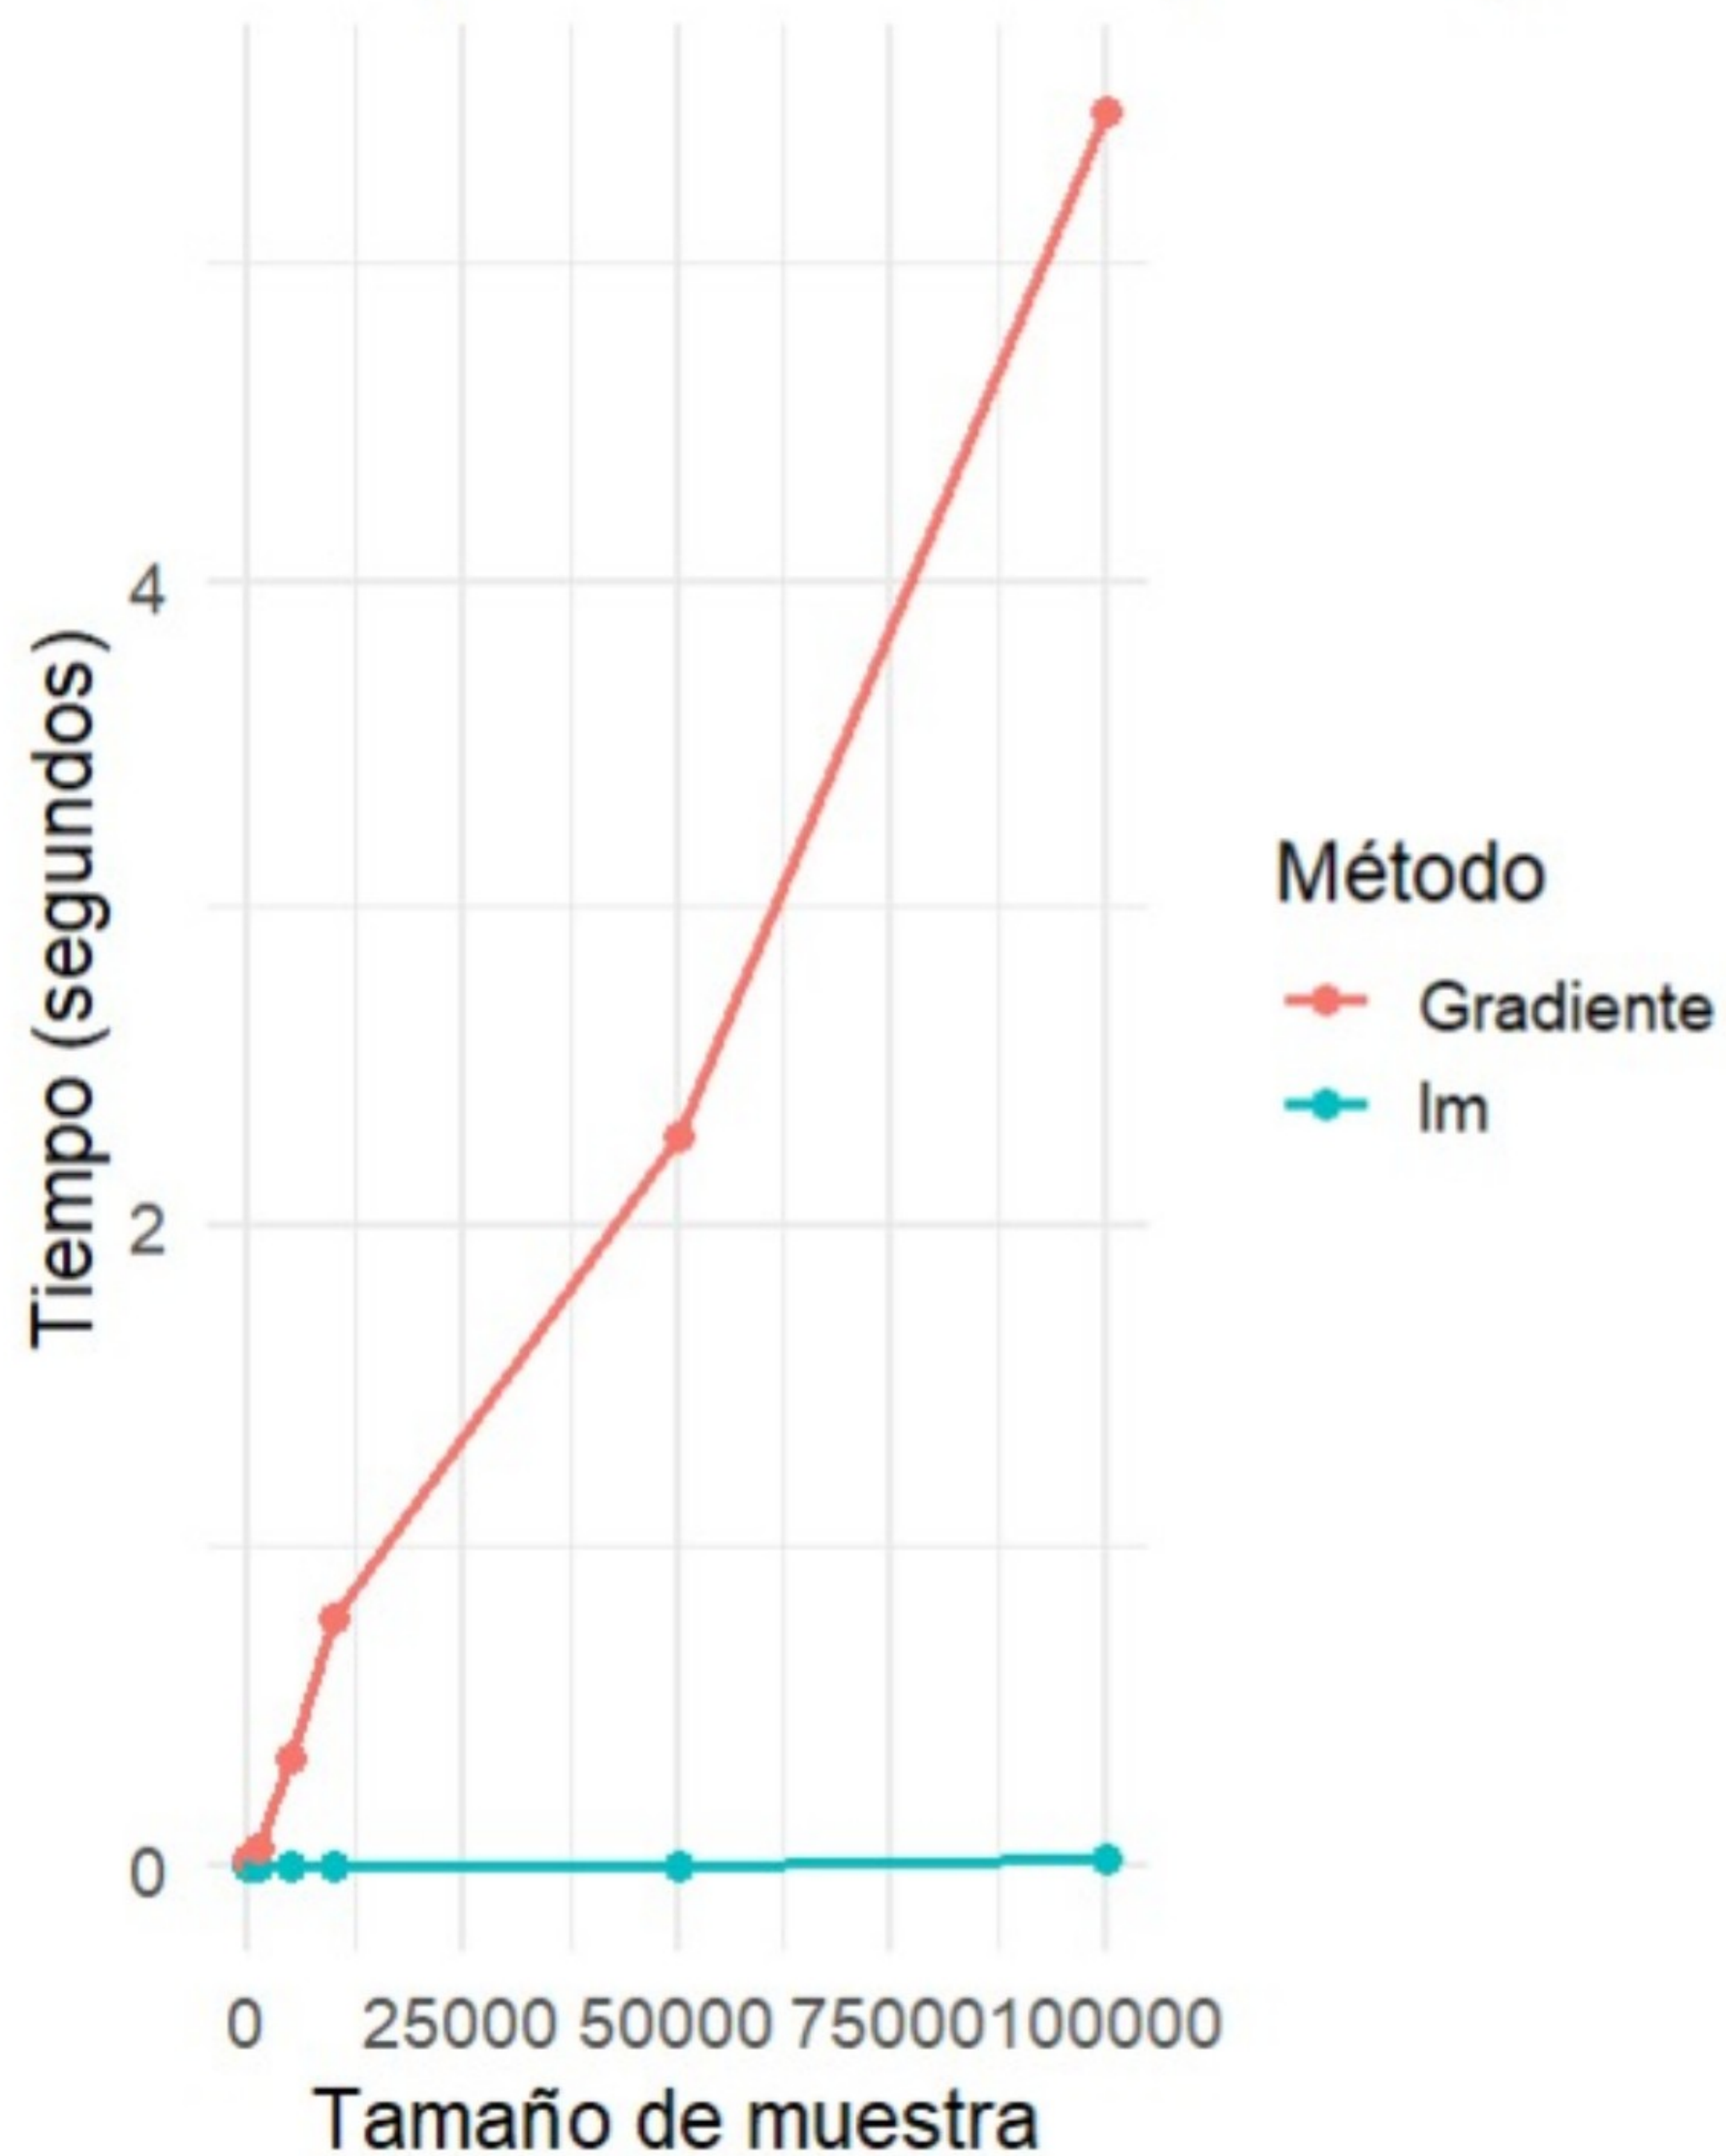
los Resultados muestran

- $lm()$  es más rapido y preciso, ya que usa algoritmo matriciales optimizados.
- El gradiente, consume menos memoria, pero tarda más tiempo porque necesita muchas iteraciones

En conclusión, ambos metodos son validos, pero su elección depende del tamaño del conjunto de datos y los recursos de computo disponible.



### Comparación de tiempo de ejecución



### Comparación de uso de memoria

